TECNOLÓGICO NACIONAL DE MÉXICO

Instituto Tecnológico de Culiacán

Aplicación de Redes Neuronales y Aprendizaje Automático para el diseño de estrategias de enfriamiento urbano

Alumnos:

Campos López Luis Fernando

Vega Hernandez Gustavo Angel

Carrera:

Ingeniería en sistemas computacionales

Materia:

Tópicos de IA

Maestro:

Zuriel Dathan Mora Félix

Índice

Glosario 3

Introducción 6

Objetivos 9

- Objetivo general 9
- Objetivos específicos 9

Justificación 11

Alcance 12

- Delimitación del proyecto 12

Marco teórico 14

- Isla de Calor Urbana (ICU) y sus Determinantes Físicos 14
- Clasificación de Cobertura de Suelo Mediante Redes Neuronales Convolucionales 15
- Clasificación de Severidad Térmica Mediante Aprendizaje Automático 16
- Distribución Espacial de la Infraestructura Verde y su Relación con el Enfriamiento Urbano 16
- Morfología Urbana y Reglas de Factibilidad Técnica 17
- Sistemas de Información Geográfica y Geoprocesamiento 18

Hipótesis 18

Desarrollo 19

- Herramientas y Tecnologías 19

Arquitectura del Sistema 20

- Plan de Desarrollo Detallado 22

Agenda 23

Conclusión 24

Referencias 26

Glosario

Isla de Calor Urbana (ICU): Fenómeno climático mediante el cual las zonas urbanizadas registran temperaturas del aire y de superficie sistemáticamente más elevadas que las de las áreas rurales circundantes, como consecuencia de la sustitución de vegetación y suelo permeable por materiales de construcción.

Temperatura de Superficie Terrestre (LST): Temperatura de la superficie del suelo medida mediante sensores remotos satelitales, se distingue de la temperatura atmosférica, que es la que efectivamente percibe una persona y está ligada al confort térmico.

Clasificación de Cobertura de Suelo: Proceso mediante el cual un modelo de aprendizaje automático asigna, a cada zona de una imagen satelital, una categoría (vegetación, suelo baldío, pavimento, construcción) según sus características espectrales y visuales.

Redes Neuronales Convolucionales (CNN): Modelos de aprendizaje profundo diseñados para el procesamiento de imágenes, capaces de extraer patrones visuales como bordes, texturas y colores mediante capas de filtros convolucionales.

Clasificación de Severidad Térmica: Tarea de aprendizaje automático que asigna a cada zona de la ciudad una categoría de riesgo (bajo, medio, alto) de isla de calor, a partir de variables como temperatura, densidad constructiva y cobertura vegetal cercana.

Mapa Prescriptivo: Producto cartográfico que, a diferencia de un mapa diagnóstico (que solo muestra un fenómeno), indica una acción o intervención recomendada para cada zona representada.

Pavimento Reflectante (material frío): Material de construcción con alto albedo, diseñado para reflejar una mayor proporción de radiación solar que el pavimento convencional, reduciendo la absorción de calor.

Infraestructura Verde Urbana: Conjunto de elementos vegetales árboles, parques, jardines dentro de la trama urbana, empleados como estrategia de regulación térmica mediante albedo y evapotranspiración.

Morfología Urbana: Conjunto de características físicas del trazado de una ciudad ancho de calles, densidad, orientación de manzanas que condicionan la viabilidad técnica de una intervención de diseño urbano.

Reglas de Factibilidad Técnica: Criterios de ingeniería (ancho de vialidad, espacio disponible, orientación solar) empleados para decidir si una zona candidata es apta para arbolado o para pavimento reflectante, aplicados sobre la salida del modelo de clasificación.

Sistema de Información Geográfica (SIG): Plataforma de software que captura, almacena, edita, analiza y visualiza datos geoespaciales, integrando capas vectoriales y ráster dentro de un mismo entorno de referencia espacial. QGIS es un SIG de código abierto.

Datos Vectoriales: Datos geoespaciales representados mediante puntos, líneas o polígonos (por ejemplo, el trazado de una calle o el límite de un lote), en contraste con los datos ráster de una imagen satelital.

Buffer Geoespacial: Herramienta de geoprocesamiento en QGIS que genera una franja o zona de influencia alrededor de un elemento (por ejemplo, una calle), utilizada para identificar qué otros elementos se encuentran cerca de él.

Unión Espacial: Operación de geoprocesamiento que combina los atributos de dos capas distintas según su posición en el espacio (por ejemplo, asignar a cada lote baldío el ancho de la calle más cercana), en lugar de un campo en común como en una unión de tablas convencional.

Inteligencia Artificial (IA): Rama de la informática que desarrolla sistemas capaces de simular procesos cognitivos humanos como el aprendizaje, la clasificación, la predicción y la toma de decisiones mediante algoritmos.

Introducción

Debido a la rápida urbanización, cada vez más ciudades de todo el mundo se ven pobladas por complejas estructuras artificiales como rascacielos y carreteras capaces de cambiar el flujo del aire y el impacto ambiental en los núcleos urbanos. Las temperaturas anormales elevadas derivadas del efecto de Isla de calor urbana (UHI, por sus siglas en inglés) contribuyen a sobrecargar los sistemas de salud publica y a incrementar el consumo energético en dichas zonas [1].

Desde mediados del siglo 20, la urbanización ha alterado significativamente las superficies naturales de la tierra, siendo reemplazadas por materiales artificiales lo que da como resultado una amplia cobertura de superficies impermeables o rugosas, un aumento de las emisiones de calor y contaminación, y una reducción de la vegetación [4].

El fenómeno de ICU afecta tres grandes sectores: ambiental (Aumento de la temperatura y procesos naturales), social (Salud) y económico (Aumento del consumo eléctrico por la temperatura).

El efecto ICU afecta críticamente al bienestar y la salud de los residentes al causar malestar térmico y aumentar los riesgos relacionados con el calor, al tiempo que debilita los esfuerzos hacia el desarrollo hacia el desarrollo urbano sostenible. Un informe reciente publicado en el The Lancet destaca que en regiones que experimentan un intenso efecto ICU, las tasas de mortalidad aumentan un 4.1% por cada incremento de 1 °C en la temperatura más allá de los 29 °C [4].

Debido a la urbanización y a las intensas actividades humanas, el efecto de ICU se ha convertido en un problema climático y ambiental cada vez más preocupante. Un estudio

reciente de la ICU global predijo que alrededor del 30% de la población mundial esta expuesta a temperaturas altas mortales durante al menos 20 días al año, y para 2100, se proyectó que esta proporción alcanzará el 48% [3].

Como resultado del fenómeno de ICU, existen problemas económicos y sociales que aumentan el uso de energía en verano y dificultan la actividad física [2]. El fenómeno de la noche tropical es uno de los problemas notables causados por la ICU porque las estructuras artificiales absorben calor, manteniendo las temperaturas de la ciudad incómodamente altas incluso de noche. Causa problemas de salud publica e incrementa el consumo energético [1].

El estudio “Uso de SIGs para la evaluación de la disponibilidad de espacios verdes urbanos en Culiacán” realizado en 2023 nos dice que la dotación de áreas verdes en la ciudad de Culiacán es de 5.3 m^2 por habitante, la cual está muy por debajo de los 9 a 15 m^2 por habitante que recomienda la Organización Mundial de la Salud (OMS). Además, de acuerdo con su disponibilidad y distribución, solo son útiles al 20% de la población [6].

Se demuestra que las zonas con mayor densidad de población tienen menor disponibilidad de áreas verdes, las cuales no todas corresponden a zonas marginadas, sino a la segunda y tercera corona de la ciudad que corresponden a espacios de más reciente formación [6].

La mayoría de los estudios que analizan el efecto de reducción de temperatura en áreas verdes han analizado el fenómeno de la isla de calor utilizando la temperatura superficial. Dado que la temperatura superficial depende del material o las características de la superficie, tiene la limitación de que difiere de la temperatura atmosférica real. La

temperatura atmosférica está directamente relacionada con el confort térmico de las personas en el espacio exterior [2].

Las estrategias de planificación urbana y desarrollo ecológico deben reconocer que el solo hecho de aumentar el área de espacio verde es insuficiente para aprovechar completamente el potencial de enfriamiento de las áreas verdes urbanas (UGS). Maximizar el rendimiento de la regulación térmica requiere una consideración integrada de la distribución espacial de las UGS, la composición estructural y los contextos ambientales locales [5].

Debido a que las estrategias actuales son muy generales y no atacan el problema desde la raíz, su impacto en la mitigación de las islas de calor es débil. Aunque en primer plano aumentar las zonas verdes debería ser la solución, por sí solo el aumento de la vegetación no tendrá un verdadero impacto. Se necesitan identificar puntos específicos en la ciudad para que estas nuevas zonas verdes maximicen su impacto, además de considerar otras herramientas como los materiales reflectantes. Para poder combatir este problema la presente investigación busca responder la siguiente pregunta: ¿es posible disminuir la isla de calor mediante el uso de inteligencia artificial, con el fin de generar un mapa que identifique de forma automática los puntos más eficientes de una ciudad para implementar arbolado o pavimento reflectante, con base en mapas térmicos satelitales utilizando un algoritmo de clasificación?

Objetivos

Objetivo general

Diseñar un sistema que integre un análisis geoespacial y modelos de inteligencia artificial capaz de generar un mapa que detecte de forma automática el lugar óptimo para arborizar o colocar pavimento reflectante, y estimar la proyección de mejora térmica con el fin de mitigar la temperatura y las islas de calor urbanas, a partir de mapas térmicos satelitales, imágenes ópticas satelitales y datos de morfología urbana.

Objetivos específicos

1. Recopilar mapas térmicos y ópticos de la ciudad a estudiar, así como datos morfológicos para obtener información como calles, banquetas, baldíos etc.

2. Entrenar un modelo de clasificación para analizar la cobertura del suelo, basado en redes neuronales convolucionales (CNN) para que sea capaz de distinguir entre vegetación, baldíos, pavimento y construcciones a partir de imágenes satelitales ópticas.

3. Entrenar un modelo de clasificación para que categorice cada zona de la ciudad según el riesgo de isla de calor (alto, medio y bajo), a partir de datos como la temperatura, la densidad de construcción y la cobertura vegetal cercana.

4. Cruzar, mediante geoprocesamiento la capa de cobertura de suelo clasificada con la capa de riesgo de isla de calor, filtrando solamente las zonas de suelo baldío o pavimento ubicadas en zonas de alto riesgo.

5. Diseñar un conjunto de reglas de factibilidad técnica que determine si una zona es buena para llevar a cabo el arbolado o pavimento reflectante.
6. Integrar la clasificación de cobertura de suelo, la clasificación de riesgo de isla de calor y las reglas de factibilidad en un solo flujo de trabajo que genere un mapa prescriptivo.
7. Generar una capa de proyección de mejora térmica, con base en el efecto de enfriamiento documentado en la literatura para intervenciones de cobertura verde similares.
8. Evaluar el rendimiento del modelo de clasificación de cobertura de suelo mediante métricas de exactitud, estableciendo como meta mínima un 85% de exactitud.
9. Evaluar el desempeño del modelo de clasificación de severidad térmica mediante su exactitud, estableciendo como meta mínima un 80%.
10. Comprobar que las recomendaciones del mapa tengan sentido, comparándolas con lo que ya se sabe sobre dónde intervenir en una ciudad y con el déficit de áreas verdes ya documentado en la zona.

Justificación

La realización de esta investigación se justifica debido al impacto directo en tres factores: impacto socioambiental, insuficiencia de las estrategias urbanas tradicionales y la necesidad de herramientas tecnológicas avanzadas para una toma de decisiones estratégicas.

El impacto socioambiental que implica el aumento de la temperatura es un problema real que causa un aumento en la mortalidad por cada grado que aumenta más allá de los 29 °C [4]. Por ejemplo, según la OMS, sólo en Europa, en 2023 fallecieron 70.000 personas como consecuencia del calor sufrido entre junio y agosto. Los colectivos más vulnerables son las personas mayores, los niños pequeños y quienes padecen enfermedades cardiovasculares, respiratorias o metabólicas [8].

Actualmente las estrategias urbanas son insuficientes para mitigar el problema debido a que no comprenden el problema, el simple hecho de aumentar el área de espacio verde es insuficiente para aprovechar completamente el potencial de enfriamiento de los espacios verdes urbanos [5].

Existe claramente una necesidad de implementar herramientas tecnologías para la mitigación del problema ya que tienen un impacto positivo: estudios demuestran como las predicciones a alta resolución pueden ayudar a proteger a las poblaciones vulnerables del calor extremo y contribuir al desarrollo urbano sostenible en todo el mundo [1]. La relación entre la infraestructura urbana y la temperatura del aire es intrínsecamente no lineal. Los métodos estadísticos lineales convencionales resultan deficientes para predecir estas dinámicas, mientras que algoritmos de aprendizaje automático como Random Forest y

XGBoost logran capturar estas interacciones complejas con un alto rendimiento predictivo [2].

Alcance

Delimitación del proyecto

El presente proyecto se enfoca en el diseño de una metodología general aplicable a cualquier ciudad que cuente con imágenes satelitales de resolución adecuada y datos vectoriales de calles disponibles para la generación de un mapa prescriptivo de mitigación de islas de calor, validando su funcionamiento con datos de la ciudad de Culiacán como caso de estudio. A continuación, se describen los componentes incluidos y excluidos.

El proyecto incluye:

- Recopilación de imágenes ópticas y térmicas (LST) de la ciudad de estudio, y de datos vectoriales de calles y uso de suelo.
- Entrenamiento de una CNN que distinga vegetación, suelo baldío, pavimento y construcción a partir de imágenes ópticas.
- Entrenamiento de un modelo Random Forest/XGBoost que categorice cada zona en riesgo bajo, medio o alto de isla de calor.
- Definición de criterios (ancho de vialidad, espacio disponible) para decidir entre arbolado o pavimento reflectante.
- Cruce de las capas anteriores en QGIS para producir el mapa final de recomendaciones.

- Estimación, por rango y no como valor exacto, de la reducción de temperatura esperada en las zonas de arbolado recomendado, con base en el efecto de enfriamiento reportado en la literatura.
- Contraste de las recomendaciones del sistema contra criterios documentados y contra el déficit de áreas verdes reportado en la literatura.

El proyecto NO incluye:

- Certificación oficial ni estudio de impacto ambiental: el mapa prescriptivo es una herramienta de apoyo a la decisión, no un dictamen ambiental vinculante ni un sustituto de los estudios que exige la normativa municipal.
- Selección de especies arbóreas ni presupuesto de implementación: el sistema recomienda dónde intervenir y con qué tipo de solución (vegetación o material reflectante), pero no determina la especie específica, el costo de los materiales ni el plan de ejecución de obra.
- Monitoreo en tiempo real: el sistema procesa imágenes satelitales históricas o recientes, pero no está diseñado como una plataforma de monitoreo continuo o de alertas en tiempo real.
- Despliegue institucional: el desarrollo llegará hasta un prototipo funcional del flujo de trabajo (script de clasificación y proyecto de QGIS); no se gestionará su integración oficial en los sistemas de las dependencias municipales.

- Predicción exacta de temperatura futura: la proyección de mejora térmica se presenta como un rango basado en evidencia documentada, no como un valor exacto en grados; el sistema no simula el comportamiento térmico futuro de una zona con precisión de decimales.

Marco teórico

Isla de Calor Urbana (ICU) y sus Determinantes Físicos

La Isla de Calor Urbana (ICU) se define como el fenómeno climático mediante el cual las zonas urbanizadas presentan temperaturas del aire y de la superficie sistemáticamente más elevadas que las de las áreas rurales circundantes, como consecuencia de la sustitución de vegetación y suelo permeable por materiales de construcción. Este efecto se explica principalmente por dos mecanismos físicos: el albedo, es decir, la fracción de radiación solar que una superficie refleja hacia la atmósfera (superficies de asfalto y concreto reflejan poco y absorben la mayor parte del calor), y la evapotranspiración, el proceso mediante el cual la vegetación libera vapor de agua consumiendo energía calorífica del entorno, generando un efecto de enfriamiento local [8], [9].

La literatura distingue dos formas de medir la ICU: la temperatura de superficie terrestre (LST), obtenida mediante sensores remotos satelitales, y la temperatura atmosférica, que es la que efectivamente percibe una persona a nivel de calle y que está directamente relacionada con el confort térmico. La mayoría de los estudios de mitigación de ICU emplean la LST como variable por su disponibilidad a gran escala, aunque se reconoce su limitación frente a la temperatura atmosférica real [2]. Chen et al. (2022)

demostraron que es posible monitorear la Isla de Calor de Dosel a una resolución de 30 metros combinando observaciones satelitales y estaciones meteorológicas mediante un modelo de Random Forest, alcanzando un ajuste de $R^2 = 0.986$, lo que sienta un precedente sólido para el uso de modelos de aprendizaje automático en este dominio [3].

Clasificación de Cobertura de Suelo Mediante Redes Neuronales Convolucionales

Las redes neuronales convolucionales (CNN) son modelos de aprendizaje profundo diseñados específicamente para el procesamiento de imágenes, capaces de extraer patrones visuales bordes, texturas, color mediante capas de filtros convolucionales aplicados sobre la imagen de entrada. En el campo de la percepción remota, las CNN se emplean ampliamente para la tarea de clasificación de cobertura de suelo: asignar, a cada zona de una imagen satelital, una categoría como vegetación, suelo desnudo, superficie impermeable (pavimento) o construcción.

Kumar, Balakrishnan y Tripathy entrenaron un modelo CNN para predecir, a partir de imágenes Landsat de 30 metros de resolución, mapas fraccionarios de cobertura construida y vegetación, validando su metodología en dos megaciudades y obteniendo un error porcentual absoluto medio de entre 7.2% y 11.3%, superando el desempeño de un clasificador de Random Forest de referencia [10]. Esta metodología es directamente aplicable al presente proyecto: el mismo tipo de arquitectura permite distinguir, dentro de la mancha urbana, entre suelo baldío o pavimento (candidatos a intervención) y vegetación o construcción ya consolidada (zonas que no requieren o no admiten intervención).

Clasificación de Severidad Térmica Mediante Aprendizaje Automático

Identificar las zonas críticas de calor de una ciudad puede abordarse mediante un modelo de clasificación que aprenda a distinguir zonas de riesgo bajo, medio y alto a partir de varias variables combinadas temperatura, densidad constructiva y cobertura vegetal cercana, en lugar de un umbral fijo. Mansouri y Erfani (2025) entrenaron clasificadores de Random Forest y XGBoost sobre más de once mil unidades censales del medio oeste estadounidense para predecir la severidad del efecto de isla de calor, logrando un desempeño discriminatorio sobresaliente (ROC-AUC > 0.90) e identificando, mediante la técnica de interpretabilidad SHAP, que la diferencia de vegetación entre zonas urbanas y rurales y el grado de impermeabilización del suelo son las variables de mayor peso predictivo [4]. El presente proyecto adopta este mismo enfoque para clasificar la severidad térmica de cada zona candidata.

Distribución Espacial de la Infraestructura Verde y su Relación con el Enfriamiento Urbano

Estudios previos como el de Jeong (2018) emplearon Random Forest para estimar el efecto de enfriamiento de áreas verdes en Seúl a partir de índices de vegetación, obteniendo un ajuste de $R^2 = 0.69$; sin embargo, este tipo de estudios trataba la cantidad de vegetación como la variable determinante del enfriamiento, sin considerar su distribución espacial dentro de la ciudad [2]. Wang et al. (2025) matizan este enfoque: mediante un análisis espacial de cuatro décadas en Beijing, demostraron que la capacidad de enfriamiento de las áreas verdes urbanas depende de su distribución espacial y composición estructural, no únicamente de la superficie total cubierta, identificando un umbral de eficiencia óptima entre el 10% y el 20% de cobertura verde por unidad de área [5].

Este hallazgo es el fundamento metodológico central del presente proyecto: si el impacto de una intervención de arbolado depende de dónde se ubique y no solo de cuánta superficie ocupe, entonces la pregunta relevante no es "cuánta vegetación añadir", sino "en qué puntos específicos de la ciudad esa vegetación generará el mayor efecto de enfriamiento posible" precisamente la pregunta que el sistema propuesto busca responder de forma automatizada.

Morfología Urbana y Reglas de Factibilidad Técnica

La morfología urbana, el ancho de las vialidades, la densidad constructiva, la orientación de las manzanas condiciona qué tipo de intervención es técnicamente viable en un espacio determinado. Un lote baldío identificado como candidato para arbolado puede no ser viable si se ubica en una vialidad demasiado angosta para permitir el desarrollo de la copa del árbol sin interferir con la circulación vehicular o peatonal en dichos casos, una solución alternativa como el pavimento reflectante puede ser más apropiada [9]. Estos criterios de factibilidad no se aprenden estadísticamente a partir de datos históricos, sino que corresponden a reglas de ingeniería ya establecidas en la práctica del diseño urbano, y se aplican como una capa de decisión posterior a la clasificación realizada por los modelos de IA.

En términos de implementación en QGIS, estas reglas no requieren ningún modelo: se resuelven con herramientas de geoprocesamiento ya integradas en el software. Mediante una operación de buffer (zona de influencia alrededor de un elemento) y una unión espacial (spatial join), se asigna a cada zona candidata el dato de ancho de la calle más cercana. Después, mediante la calculadora de campos de QGIS equivalente a escribir una fórmula condicional sobre una columna, como en una hoja de cálculo, se aplica la regla de decisión

(por ejemplo, ancho de calle mayor a determinado umbral implica que se recomienda arbolado; en caso contrario, pavimento reflectante).

Sistemas de Información Geográfica y Geoprocesamiento

Un Sistema de Información Geográfica (SIG) es la plataforma de software que captura, almacena, edita, analiza y visualiza datos geoespaciales, integrando capas vectoriales (polígonos, líneas, puntos) y ráster (imágenes satelitales) dentro de un mismo entorno de referencia espacial. En años recientes, los SIG han sido ampliamente utilizados para evaluar la disponibilidad y distribución de áreas verdes urbanas, incluyendo estudios enfocados específicamente en la ciudad de Culiacán [6]. Para el presente proyecto, QGIS un SIG de código abierto y multiplataforma cumple tres funciones instrumentales: la superposición de la capa de cobertura de suelo clasificada con la capa de severidad térmica, la incorporación de la capa vectorial de morfología urbana para aplicar las reglas de factibilidad, y la generación visual del mapa prescriptivo final.

Hipótesis

Si se integra un modelo de clasificación de cobertura de suelo basado en redes neuronales convolucionales con un modelo de clasificación de severidad térmica basado en Random Forest/XGBoost, mediante geoprocesamiento en QGIS y un conjunto de reglas de factibilidad técnica, entonces sera posible generar de forma automática un mapa prescriptivo que identifique las zonas óptimas de una ciudad para arbolado o pavimento reflectante, y estimar por rango la mejora térmica esperada en dichas zonas, logrando una mitigación del efecto de Isla de Calor Urbana más dirigida y eficiente que las estrategias generales actualmente empleadas.

De esta hipótesis se derivan dos supuestos: primero, que la severidad térmica de una zona puede clasificarse de forma confiable combinando temperatura, densidad constructiva y cobertura vegetal cercana, sin necesidad de predecir un valor exacto de temperatura; y segundo, que la factibilidad de una intervención (arbolado o pavimento reflectante) puede determinarse mediante reglas de ingeniería aplicadas sobre la morfología urbana, sin que dicho criterio deba aprenderse estadísticamente a partir de datos históricos.

Desarrollo

Herramientas y Tecnologías

La selección de herramientas se realizó considerando criterios de eficiencia, accesibilidad, documentación disponible y compatibilidad entre las tecnologías de percepción remota, aprendizaje profundo y análisis geoespacial.

- Python: lenguaje elegido por su amplio ecosistema de bibliotecas de aprendizaje profundo y procesamiento geoespacial, y por su facilidad de integración con QGIS mediante su consola de Python.
- TensorFlow / Keras: framework empleado para el entrenamiento del modelo CNN de clasificación de cobertura de suelo.
- scikit-learn / XGBoost: bibliotecas empleadas para entrenar el modelo de clasificación de severidad térmica a partir de temperatura, densidad y cobertura vegetal cercana.

- QGIS (con consola de Python): Sistema de Información Geográfica de código abierto, empleado para el geoprocesamiento, la incorporación de morfología urbana y la generación visual del mapa prescriptivo final.
- GDAL / OGR: bibliotecas de manejo de formatos geoespaciales, integradas en QGIS, para la lectura y conversión de imágenes satelitales y datos vectoriales.
- Google Earth Engine: plataforma en la nube empleada opcionalmente para el acceso y preprocesamiento de imágenes satelitales históricas (Landsat, Sentinel).
- OpenStreetMap (Overpass API): fuente gratuita de datos vectoriales de calles y morfología urbana.
- GPU local / Google Colab: el entrenamiento de los modelos se realizará aprovechando la tarjeta gráfica disponible localmente; en caso de limitaciones de cómputo, se empleará Google Colab como alternativa gratuita de acceso a GPU en la nube.

Arquitectura del Sistema

El sistema propuesto sigue una arquitectura de tres etapas: una capa de aprendizaje automático (clasificación de cobertura de suelo mediante CNN, y clasificación de severidad térmica mediante Random Forest/XGBoost), una capa de reglas de ingeniería (factibilidad técnica, resuelta con geoprocesamiento simple en QGIS, sin modelos) y, finalmente, una

capa de proyección que traduce el mapa prescriptivo en una estimación visual de la mejora térmica esperada. El flujo de trabajo completo se describe a continuación:

Paso 1: la imagen óptica satelital (Sentinel/Landsat) se procesa con el modelo CNN, que genera una capa de cobertura de suelo con cuatro categorías (vegetación, baldío, pavimento, construcción).

Paso 2: la temperatura de superficie, la densidad constructiva y la cobertura vegetal cercana se procesan con el modelo Random Forest/XGBoost, que genera una capa de severidad térmica (bajo, medio, alto).

Paso 3: en QGIS, se cruzan ambas capas, conservando únicamente las zonas de suelo baldío o pavimento que además se ubican en una zona de severidad alta.

Paso 4: cada zona candidata se contrasta contra la capa vectorial de calles (OpenStreetMap) mediante buffer y unión espacial, y se le aplican las reglas de factibilidad técnica (ancho de vialidad, espacio disponible) para decidir entre arbolado o pavimento reflectante.

Paso 5: QGIS genera el mapa prescriptivo final, coloreando cada zona según la intervención recomendada (verde = arbolado, gris claro = pavimento reflectante).

Paso 6: para cada zona marcada con arbolado, se superpone una capa de proyección de mejora térmica, expresada como un rango de reducción de temperatura (y no como un valor exacto), con base en el efecto de enfriamiento documentado por Wang et al. (2025) para intervenciones de cobertura verde similares [5].

Esta arquitectura separa claramente lo que un modelo de IA puede aprender de datos reales (dónde hay vegetación, dónde hace más calor) de lo que corresponde a un criterio de

ingeniería ya establecido (dónde cabe físicamente un árbol) y de lo que corresponde a evidencia de literatura (cuánto se espera que enfríe una intervención de este tipo), evitando en los tres casos que el sistema le pida al componente estadístico una precisión que no puede sostener.

Plan de Desarrollo Detallado

Fase 1 (2 semanas): recolección de imágenes ópticas y térmicas (Landsat/Sentinel) y de datos vectoriales de calles (OpenStreetMap) para la ciudad de estudio.

Fase 2 (3 semanas): etiquetado de muestras y entrenamiento del modelo CNN de clasificación de cobertura de suelo, con meta mínima de 85% de exactitud.

Fase 3 (2 semanas): entrenamiento del modelo Random Forest/XGBoost de severidad térmica, con meta mínima de 80% de exactitud; construcción del proyecto QGIS y overlay de capas.

Fase 4 (2 semanas): definición e implementación de las reglas de factibilidad técnica; integración del pipeline completo.

Fase 5 (2 semanas): generación del mapa prescriptivo final, validación contra criterios documentados y redacción del informe.

Métricas de Evaluación

Modelo de clasificación de cobertura de suelo: exactitud global y matriz de confusión entre las cuatro categorías (vegetación, baldío, pavimento, construcción).

Modelo de clasificación de severidad térmica: exactitud global entre las tres categorías de riesgo, e importancia de variables para verificar que el modelo pondera de

forma coherente cada factor, siguiendo el enfoque de interpretabilidad de Mansouri y Erfani (2025) [4].

Validación del sistema completo: proporción de zonas recomendadas por el sistema que coinciden con zonas de déficit de áreas verdes ya documentadas para la ciudad de estudio [6], y revisión cualitativa de una muestra del mapa por criterio experto.

Agenda

El desarrollo del proyecto se organiza en once semanas de trabajo, alineadas con las cinco fases descritas en el Plan de Desarrollo Detallado:

Semana	Actividades	Entregable
Semana 1	Revisión bibliográfica final y gestión de acceso a imágenes satelitales (Landsat/Sentinel) y datos de OpenStreetMap para la ciudad de estudio.	Fuentes de datos identificadas y accesibles
Semana 2	Descarga y preprocesamiento de imágenes ópticas y térmicas; limpieza y homologación de los datos vectoriales de calles.	Base de datos geoespacial consolidada
Semana 3	Etiquetado de muestras de entrenamiento (vegetación, baldío, pavimento, construcción) para el modelo CNN.	Conjunto de datos etiquetado
Semana 4	Entrenamiento inicial del modelo CNN de clasificación de cobertura de suelo.	Modelo CNN (versión 1) y métricas iniciales
Semana 5	Ajuste de hiperparámetros y validación del modelo CNN hasta alcanzar la meta mínima de 85% de exactitud.	Modelo CNN final
Semana 6	Construcción de las variables de temperatura, densidad y cobertura vegetal cercana, y entrenamiento del modelo Random Forest/XGBoost de severidad térmica.	Modelo de severidad entrenado

Semana	Actividades	Entregable
Semana 7	Validación del modelo de severidad térmica (meta mínima de 80% de exactitud) y construcción del proyecto QGIS con overlay de capas.	Capa de zonas candidatas
Semana 8	Incorporación de la capa de morfología urbana y definición de las reglas de factibilidad técnica.	Reglas de factibilidad documentadas
Semana 9	Implementación de las reglas de factibilidad en QGIS e integración del pipeline completo, de extremo a extremo.	Pipeline funcional
Semana 10	Generación del mapa prescriptivo final y de la capa de proyección de mejora térmica; validación contra criterios documentados.	Mapa prescriptivo y reporte de validación
Semana 11	Redacción del documento final y preparación de la presentación.	Documento completo y presentación

Conclusión

El presente protocolo ha demostrado, a partir de la revisión de la literatura especializada, que existe una base científica sólida para sustentar la viabilidad técnica de un sistema que combine dos modelos de aprendizaje automático clasificación de cobertura de suelo y clasificación de severidad térmica con análisis geoespacial, para generar recomendaciones de mitigación de la Isla de Calor Urbana dirigidas a puntos específicos de la ciudad. El hallazgo de Wang et al. (2025) sobre la importancia de la distribución espacial y no solo la cantidad de la infraestructura verde [5] constituye el fundamento metodológico central de la propuesta; los antecedentes de clasificación de cobertura de suelo mediante CNN [10] y de clasificación de severidad de isla de calor mediante Random Forest/XGBoost [4] confirman que ambas etapas de aprendizaje automático del sistema son técnicamente alcanzables con enfoques ya validados en la literatura.

La aportación original de este proyecto reside en la separación explícita entre lo que un modelo de inteligencia artificial puede aprender de forma confiable a partir de datos reales dónde hay vegetación, suelo baldío o pavimento, y dónde se concentra el calor y lo que corresponde a un criterio de ingeniería ya establecido qué tipo de intervención es físicamente viable en cada espacio. Esta arquitectura evita pedirle al componente estadístico decisiones que no puede sostener con evidencia, y en su lugar produce un mapa prescriptivo accionable, útil tanto para priorizar la inversión pública en zonas verdes como para orientar la planeación urbana en ciudades con un déficit de áreas verdes documentado, como es el caso de Culiacán [6].

Desde el punto de vista de la ingeniería en sistemas, la viabilidad técnica del proyecto es alta: todas las herramientas seleccionadas (Python, TensorFlow, QGIS, datos satelitales y de OpenStreetMap) son de código abierto o de acceso gratuito, y trabajan exclusivamente con datos de la ciudad ya construida, lo que evita las limitaciones de predicción sobre escenarios hipotéticos. El principal reto identificado es la disponibilidad de imágenes satelitales libres de nubosidad y de datos vectoriales suficientemente detallados para aplicar las reglas de factibilidad con precisión, por lo que la recolección de datos se mantiene como la actividad crítica del cronograma propuesto. En su conjunto, el protocolo aquí presentado sienta las bases metodológicas para el desarrollo de una herramienta de ingeniería con aplicación directa en la mitigación del efecto de Isla de Calor Urbana.

Referencias

[1] Song, M., Han, S., Lee, S., Ahn, D., Kim, J., & Cha, M. (2025). Measuring fine-grained urban air temperature with satellite imagery. *Proceedings of the AAAI Conference on Artificial Intelligence*, 39, 28403.

[2] Jeong, H. (2018). *Estimating cooling effect of urban green areas using Random Forest prediction model* [Tesis de maestría, Ulsan National Institute of Science and Technology]. Repositorio UNIST.

[3] Chen, S., Yang, Y., Deng, F., Zhang, Y., Liu, D., Liu, C., & Gao, Z. (2022). A high-resolution monitoring approach of canopy urban heat island using a random forest model and multi-platform observations. *Atmospheric Measurement Techniques*, 15(3), 735–756. https://doi.org/10.5194/amt-15-735-2022.

[4] Mansouri, A., & Erfani, A. (2025). Machine learning prediction of urban heat island severity in the Midwestern United States. *Sustainability*, 17(13), 6193. https://doi.org/10.3390/su17136193.

[5] Wang, C., Yang, C., Wang, H., & Yang, L. (2025). Spatiotemporal evolution and driving factors of the cooling capacity of urban green spaces in Beijing over the past four decades. *Sustainability*, 17(21), 9500.

https://doi.org/10.3390/su17219500

[6] Ley-Aispuro, E., Torrecillas Núñez, C. E., Bojórquez, E., & Morán Delgado, G. (2023). Uso de SIGs para la evaluación de la disponibilidad de espacios verdes urbanos en Culiacán. *Revista Ingeniería y Tecnología UAS*, (5), 179–214.

[7] Ciencia UNAM. (s. f.). *Islas de calor, un fenómeno de las ciudades*. Universidad Nacional Autónoma de México.

[8] Fundación Aquae. (s. f.). *Islas de calor urbanas: El desafío de enfriar las ciudades*.

[9] Iberdrola. (s. f.). *Las islas de calor urbanas y sus efectos adversos para sus habitantes*.

[10] Kumar, P. K., Balakrishnan, K., & Tripathy, P. (2021). *A CNN based method for Sub-pixel Urban Land Cover Classification using Landsat-5 TM and Resourcesat-1 LISS-IV Imagery*. arXiv:2112.08841.